

## 矩阵求导术 (下)



长躯鬼侠  
数学爱好者

1,831 人赞同了该文章

本文承接上篇 [zhuanlan.zhihu.com/p/24...](https://zhuanlan.zhihu.com/p/24...)，来讲矩阵对矩阵的求导术。使用小写字母  $x$  表示标量，粗体小写字母  $\mathbf{x}$  表示列向量，大写字母  $X$  表示矩阵。矩阵对矩阵的求导采用了向量化的思路，常应用于二阶方法中 Hessian 矩阵的分析。

首先来琢磨一下定义。矩阵对矩阵的导数，需要什么样的定义？第一，矩阵  $F(p \times q)$  对矩阵  $X(m \times n)$  的导数应包含所有  $mnpq$  个偏导数  $\frac{\partial F_{kl}}{\partial X_{ij}}$ ，从而不损失信息；第二，导数与微分有简明的联系，

因为在计算导数和应用中需要这个联系；第三，导数有简明的从整体出发的算法。我们先定义向量

$$\mathbf{f} (p \times 1) \text{ 对向量 } \mathbf{x} (m \times 1) \text{ 的导数 } \frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} & \cdots & \frac{\partial f_p}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_p}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_1}{\partial x_m} & \frac{\partial f_2}{\partial x_m} & \cdots & \frac{\partial f_p}{\partial x_m} \end{bmatrix} (m \times p), \text{ 有}$$

$d\mathbf{f} = \frac{\partial \mathbf{f}}{\partial \mathbf{x}}^T d\mathbf{x}$ ；再定义矩阵的（按列优先）向量化

$\text{vec}(X) = [X_{11}, \dots, X_{m1}, X_{12}, \dots, X_{m2}, \dots, X_{1n}, \dots, X_{mn}]^T (mn \times 1)$ ，并定义矩

阵  $F$  对矩阵  $X$  的导数  $\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}$  ( $mn \times pq$ )。导数与微分有联系

$\text{vec}(dF) = \frac{\partial F}{\partial X}^T \text{vec}(dX)$ 。几点说明如下：

1. 按此定义，标量  $f$  对矩阵  $X(m \times n)$  的导数  $\frac{\partial f}{\partial X}$  是  $mn \times 1$  向量，与上篇的定义不兼容，不过二者容

易相互转换。为避免混淆，用记号  $\nabla_X f$  表示上篇定义的  $m \times n$  矩阵，则有

$$\frac{\partial f}{\partial X} = \text{vec}(\nabla_X f)。虽然本篇的技术可以用于标量对矩阵求导这种特殊情况，但使用上篇$$

中的技术更方便。读者可以通过上篇中的算例试验两种方法的等价转换。

2. 标量对矩阵的二阶导数，又称 Hessian 矩阵，定义为  $\nabla_X^2 f = \frac{\partial^2 f}{\partial X^2} = \frac{\partial \nabla_X f}{\partial X} (mn \times mn)$ ，

## 知乎

方便。

$$3. \frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial X} = \frac{\partial F}{\partial \text{vec}(X)} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}, \text{ 求导时矩阵被向量化, 弊端是这在一定}$$

程度破坏了矩阵的结构, 会导致结果变得形式复杂; 好处是多元微积分中关于梯度、Hessian矩阵的结论可以沿用过来, 只需将矩阵向量化。例如优化问题中, 牛顿法的更新  $\Delta X$ , 满足  $\text{vec}(\Delta X) = -(\nabla_X^2 f)^{-1} \text{vec}(\nabla_X f)$ 。

$$4. \text{ 在资料中, 矩阵对矩阵的导数还有其它定义, 比如 } \frac{\partial F}{\partial X} = \left[ \frac{\partial F_{kl}}{\partial X} \right] (mp \times nq), \text{ 或是}$$

$$\frac{\partial F}{\partial X} = \left[ \frac{\partial F}{\partial X_{ij}} \right] (mp \times nq), \text{ 它能兼容上篇中的标量对矩阵导数的定义, 但微分与导数的联}$$

系 ( $dF$  等于  $\frac{\partial F}{\partial X}$  中逐个  $m \times n$  子块分别与  $dX$  做内积) 不够简明, 不便于计算和应用。资料[5]综

述了以上定义, 并批判它们是坏的定义, 能配合微分运算的才是好的定义。

5. 在资料中, 有分子布局 and 分母布局两种定义, 其中向量对向量的导数的排布有所不同。本文使用的是分母布局, 机器学习和优化中的梯度矩阵采用此定义。而控制论等领域中的 Jacobian 矩阵

$$\text{采用分子布局, 向量 } \mathbf{f} \text{ 对向量 } \mathbf{x} \text{ 的导数定义是 } \frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_m} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_m} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_p}{\partial x_1} & \frac{\partial f_p}{\partial x_2} & \cdots & \frac{\partial f_p}{\partial x_m} \end{bmatrix}, \text{ 对应}$$

地导数与微分的联系是  $d\mathbf{f} = \frac{\partial \mathbf{f}}{\partial \mathbf{x}} d\mathbf{x}$ ; 同样通过向量化定义矩阵  $F$  对矩阵  $X$  的导数

$$\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}, \text{ 有 } \text{vec}(dF) = \frac{\partial F}{\partial X} \text{vec}(dX). \text{ 两种布局下的导数互为转置, 二者}$$

求微分的步骤是相同的, 仅在对照导数与微分的联系时有一个转置的区别, 读者可根据所在领域的习惯选定一种布局。

然后来建立运算法则。仍然要利用导数与微分的联系  $\text{vec}(dF) = \frac{\partial F}{\partial X}^T \text{vec}(dX)$ , 求微分的方法与上篇相同, 而从微分得到导数需要一些向量化的技巧:

1. 线性:  $\text{vec}(A + B) = \text{vec}(A) + \text{vec}(B)$ 。
2. 矩阵乘法:  $\text{vec}(AXB) = (B^T \otimes A) \text{vec}(X)$ , 其中  $\otimes$  表示 Kronecker 积,  $A(m \times n)$  与  $B(p \times q)$  的 Kronecker 积是  $A \otimes B = [A_{ij} B]$  ( $mp \times nq$ )。此式证明见张贤达《矩阵分析与用》第107-108页。

## 知乎

$$K_{22} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \text{vec}(A^T) = \begin{bmatrix} A_{11} \\ A_{12} \\ A_{21} \\ A_{22} \end{bmatrix}, \text{vec}(A) = \begin{bmatrix} A_{11} \\ A_{21} \\ A_{12} \\ A_{22} \end{bmatrix}.$$

4. 逐元素乘法:  $\text{vec}(A \odot X) = \text{diag}(A)\text{vec}(X)$ , 其中  $\text{diag}(A)$  ( $mn \times mn$ ) 是用  $A$  的元素 (按列优先) 排成的对角阵。

观察一下可以断言, 若矩阵函数  $F$  是矩阵  $X$  经加减乘法、逆、行列式、逐元素函数等运算构成, 则使用相应的运算法则对  $F$  求微分, 再做向量化并使用技巧将其它项交换至  $\text{vec}(dX)$  左侧, 对照导数与微分的联系  $\text{vec}(dF) = \frac{\partial F^T}{\partial X} \text{vec}(dX)$ , 即能得到导数。

特别地, 若矩阵退化为向量, 对照导数与微分的联系  $df = \frac{\partial f^T}{\partial x} dx$ , 即能得到导数。

再谈一谈复合: 假设已求得  $\frac{\partial F}{\partial Y}$ , 而  $Y$  是  $X$  的函数, 如何求  $\frac{\partial F}{\partial X}$  呢? 从导数与微分的联系入手,

$$\text{vec}(dF) = \frac{\partial F^T}{\partial Y} \text{vec}(dY) = \frac{\partial F^T}{\partial Y} \frac{\partial Y^T}{\partial X} \text{vec}(dX), \text{ 可以推出链式法则}$$

$$\frac{\partial F}{\partial X} = \frac{\partial Y}{\partial X} \frac{\partial F}{\partial Y}.$$

和标量对矩阵的导数相比, 矩阵对矩阵的导数形式更加复杂, 从不同角度出发常会得到形式不同的结果。有一些 Kronecker 积和交换矩阵相关的恒等式, 可用来做等价变形:

1.  $(A \otimes B)^T = A^T \otimes B^T$ 。
2.  $\text{vec}(ab^T) = b \otimes a$ 。
3.  $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$ 。可以对  $F = D^T B^T X A C$  求导来证明, 一方面, 直接求导得到  $\frac{\partial F}{\partial X} = (AC) \otimes (BD)$ ; 另一方面, 引入  $Y = B^T X A$ , 有  $\frac{\partial F}{\partial Y} = C \otimes D, \frac{\partial Y}{\partial X} = A \otimes B$ , 用链式法则得到  $\frac{\partial F}{\partial X} = (A \otimes B)(C \otimes D)$ 。
4.  $K_{mn} = K_{nm}^T, K_{mn} K_{nm} = I$ 。
5.  $K_{pm}(A \otimes B)K_{nq} = B \otimes A$ ,  $A$  是  $m \times n$  矩阵,  $B$  是  $p \times q$  矩阵。可以对  $AXB^T$  做向量化来证明, 一方面,  $\text{vec}(AXB^T) = (B \otimes A)\text{vec}(X)$ ; 另一方面,



# 知乎

接下来演示一些算例。

例1:  $F = AX$ ,  $X$ 是 $m \times n$ 矩阵, 求  $\frac{\partial F}{\partial X}$ 。

解: 先求微分:  $dF = AdX$ , 再做向量化, 使用矩阵乘法的技巧, 注意在 $dX$ 右侧添加单位阵:

$\text{vec}(dF) = \text{vec}(AdX) = (I_n \otimes A)\text{vec}(dX)$ , 对照导数与微分的联系得到

$$\frac{\partial F}{\partial X} = I_n \otimes A^T.$$

特例: 如果 $X$ 退化为向量, 即  $f = Ax$ , 则根据向量的导数与微分的关系  $df = \frac{\partial f}{\partial x} dx$ , 得

$$\frac{\partial f}{\partial x} = A^T.$$

例2:  $f = \log |X|$ ,  $X$ 是 $n \times n$ 矩阵, 求  $\nabla_X f$  和  $\nabla_X^2 f$ 。

解: 使用上篇中的技术可求得  $\nabla_X f = X^{-1T}$ 。为求  $\nabla_X^2 f$ , 先求微分:

$d\nabla_X f = -(X^{-1}dXX^{-1})^T$ , 再做向量化, 使用转置和矩阵乘法的技巧

$\text{vec}(d\nabla_X f) = -K_{nn}\text{vec}(X^{-1}dXX^{-1}) = -K_{nn}(X^{-1T} \otimes X^{-1})\text{vec}(dX)$ , 对照导数与微分的联系, 得到  $\nabla_X^2 f = -K_{nn}(X^{-1T} \otimes X^{-1})$ , 注意它是对称矩阵。在  $X$  是对称矩阵时, 可简化为  $\nabla_X^2 f = -X^{-1} \otimes X^{-1}$ 。

例3:  $F = A \exp(XB)$ ,  $A$ 是 $l \times m$ 矩阵,  $X$ 是 $m \times n$ 矩阵,  $B$ 是 $n \times p$ 矩阵,  $\exp$ 为逐元素函数, 求  $\frac{\partial F}{\partial X}$ 。

解: 先求微分:  $dF = A(\exp(XB) \odot (dXB))$ , 再做向量化, 使用矩阵乘法的技巧:

$\text{vec}(dF) = (I_p \otimes A)\text{vec}(\exp(XB) \odot (dXB))$ , 再用逐元素乘法的技巧:

$\text{vec}(dF) = (I_p \otimes A)\text{diag}(\exp(XB))\text{vec}(dXB)$ , 再用矩阵乘法的技巧:

$\text{vec}(dF) = (I_p \otimes A)\text{diag}(\exp(XB))(B^T \otimes I_m)\text{vec}(dX)$ , 对照导数与微分的联系得

$$\frac{\partial F}{\partial X} = (B \otimes I_m)\text{diag}(\exp(XB))(I_p \otimes A^T).$$



## 知乎

解：使用上篇中的技术可求得  $\nabla_{\mathbf{w}} l = \mathbf{x}(\sigma(\mathbf{x}^T \mathbf{w}) - y)$ ，其中  $\sigma(a) = \frac{\exp(a)}{1 + \exp(a)}$  为

sigmoid函数。为求  $\nabla_{\mathbf{w}}^2 l$ ，先求微分： $d\nabla_{\mathbf{w}} l = \mathbf{x}\sigma'(\mathbf{x}^T \mathbf{w})\mathbf{x}^T d\mathbf{w}$ ，其中

$\sigma'(a) = \frac{\exp(a)}{(1 + \exp(a))^2}$  为sigmoid函数的导数，对照导数与微分的联系，得到

$$\nabla_{\mathbf{w}}^2 l = \mathbf{x}\sigma'(\mathbf{x}^T \mathbf{w})\mathbf{x}^T。$$

推广：样本  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$ ， $l = \sum_{i=1}^N (-y_i \mathbf{x}_i^T \mathbf{w} + \log(1 + \exp(\mathbf{x}_i^T \mathbf{w})))$ ，

求  $\nabla_{\mathbf{w}} l$  和  $\nabla_{\mathbf{w}}^2 l$ 。有两种方法，解1：先对每个样本求导，然后相加；解2：定义矩阵

$$X = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix}, \text{ 向量 } \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}, \text{ 将 } l \text{ 写成矩阵形式}$$

$l = -\mathbf{y}^T X\mathbf{w} + \mathbf{1}^T \log(\mathbf{1} + \exp(X\mathbf{w}))$ ，进而可以使用上篇中的技术求得

$\nabla_{\mathbf{w}} l = X^T(\sigma(X\mathbf{w}) - \mathbf{y})$ 。为求  $\nabla_{\mathbf{w}}^2 l$ ，先求微分，再用逐元素乘法的技巧：

$d\nabla_{\mathbf{w}} l = X^T(\sigma'(X\mathbf{w}) \odot (X d\mathbf{w})) = X^T \text{diag}(\sigma'(X\mathbf{w})) X d\mathbf{w}$ ，对照导数与微分的联系，得到  $\nabla_{\mathbf{w}}^2 l = X^T \text{diag}(\sigma'(X\mathbf{w})) X$ 。

例5【多元logistic回归】：

$l = -\mathbf{y}^T \log \text{softmax}(W\mathbf{x}) = -\mathbf{y}^T W\mathbf{x} + \log(\mathbf{1}^T \exp(W\mathbf{x}))$ ，求  $\nabla_W l$  和  $\nabla_W^2 l$ 。  
其中其中  $\mathbf{y}$  是除一个元素为1外其它元素为0的  $m \times 1$  列向量， $W$  是  $m \times n$  矩阵， $\mathbf{x}$  是  $n \times 1$  列向量， $l$  是标量。

解：上篇中已求得  $\nabla_W l = (\text{softmax}(W\mathbf{x}) - \mathbf{y})\mathbf{x}^T$ 。为求  $\nabla_W^2 l$ ，先求微分：定义

$$\mathbf{a} = W\mathbf{x},$$

$d\nabla_W l = \left( \frac{\exp(\mathbf{a}) \odot d\mathbf{a}}{\mathbf{1}^T \exp(\mathbf{a})} - \frac{\exp(\mathbf{a})(\mathbf{1}^T (\exp(\mathbf{a}) \odot d\mathbf{a}))}{(\mathbf{1}^T \exp(\mathbf{a}))^2} \right) \mathbf{x}^T = \left( \frac{\text{diag}(\exp(\mathbf{a}))}{\mathbf{1}^T \exp(\mathbf{a})} - \frac{\exp(\mathbf{a}) \exp(\mathbf{a})^T}{(\mathbf{1}^T \exp(\mathbf{a}))^2} \right) d\mathbf{a} \mathbf{x}^T$   
 $= (\text{diag}(\text{softmax}(\mathbf{a})) - \text{softmax}(\mathbf{a})\text{softmax}(\mathbf{a})^T) d\mathbf{a} \mathbf{x}^T$ ，注意这里化简去掉逐元素乘法，第一项中  $\exp(\mathbf{a}) \odot d\mathbf{a} = \text{diag}(\exp(\mathbf{a})) d\mathbf{a}$ ，第二项中

$$\mathbf{1}^T (\exp(\mathbf{a}) \odot d\mathbf{a}) = \exp(\mathbf{a})^T d\mathbf{a}。定义矩阵$$

$$D(\mathbf{a}) = \text{diag}(\text{softmax}(\mathbf{a})) - \text{softmax}(\mathbf{a})\text{softmax}(\mathbf{a})^T,$$

$d\nabla_W l = D(\mathbf{a}) d\mathbf{a} \mathbf{x}^T = D(W\mathbf{x}) dW \mathbf{x} \mathbf{x}^T$ ，做向量化并使用矩阵乘法的技巧，得到

$$\nabla_W^2 l = (\mathbf{x} \mathbf{x}^T) \otimes D(W\mathbf{x})。$$



# 知乎

对矩阵的导数与微分的联系是  $df = \text{tr}(\nabla_X^T f dX)$ ，先对f求微分，再使用迹技巧可求得导数，特别地，标量对向量的导数与微分的联系是  $df = \nabla_x^T f dx$ ；矩阵对矩阵的导数与微分的联系是  $\text{vec}(dF) = \frac{\partial F^T}{\partial X} \text{vec}(dX)$ ，先对F求微分，再使用向量化技巧可求得导数，特别地，向量对向量的导数与微分的联系是  $df = \frac{\partial f^T}{\partial x} dx$ 。

参考资料：

1. 张贤达. *矩阵分析与应用*. 清华大学出版社有限公司, 2004.
2. Fackler, Paul L. "Notes on matrix calculus." *North Carolina State University*(2005).
3. Petersen, Kaare Brandt, and Michael Syskind Pedersen. "The matrix cookbook." *Technical University of Denmark* 7 (2008): 15.
4. HU, Pili. "Matrix Calculus: Derivation and Simple Application." (2012).
5. Magnus, Jan R., and Heinz Neudecker. "Matrix Differential Calculus with Applications in Statistics and Econometrics." Wiley, 2019.

编辑于 2020-06-28

矩阵分析   机器学习   优化

▲ 赞同 1831   ▼   ● 221 条评论   ➦ 分享   ❤ 喜欢   ★ 收藏   📄 申请转载   ...

## 推荐阅读

### 矩阵求导术（上）

矩阵求导的技术，在统计学、控制论、机器学习等领域有广泛的应用。鉴于我看过的一些资料或言之不详、或繁乱无绪，本文来做个科普，分作两篇，上篇讲标量对矩阵的求导术，下篇讲矩阵对矩阵的...

### 矩阵求导浅析（一）

本文主要关注标量函数对矩阵的求导，并提供一种简明直观易操作的矩阵求导方法。推荐矩阵求导的专栏文章：矩阵求导术（上）矩阵求导术（下）机器学习中的向量求导 1.内积 向量

221 条评论

⇌ 切换为时间排序

写下你的评论...



菠萝打几折

2017-01-22

我只是想吐槽知乎这个狗屎编辑器到现在都不支持 MathJax，真是废物。怕是坦桑尼亚的民族风情网站都支持 MathJax 了。可能知乎的前端一没高分屏，二没大学文凭。

46



依树影魅 回复 菠萝打几折

2019-12-19

坦桑尼亚的民族风情网站网址是？

6



scarff 回复 依树影魅

2020-01-07

哈哈哈哈哈哈哈哈哈哈

赞



王赞 Maigo

2017-01-22

矩阵对矩阵求导的结果中有好多Kronecker积啊.....不过也没办法，把一个本来是四维的东西压成两维已经不容易了。

36



科技猛兽

2019-06-08

这两篇文章堪称经典，避免了读者阅读大部头的书籍，费时费力，同时讲解的真心不错，只要学过线性代数的都没压力，赞

7



bupt-lin

2018-05-05

给新手梳理了一个方向，不至于一开始就沉陷于浩瀚的矩阵分析理论中，张贤达的矩阵分析真的是一大块砖头，让人望而却步！

4



Caithen

2018-11-20

你怎么这么牛

3





## 知乎

与的并集，但这里子集的性质同效的对于A、B：

👍 3



强颜欢笑

2019-07-21

交换矩阵能不能在多说明一下？

👍 2



Boy Hey

2018-02-12

大多数资料中（如“The matrix cookbook”）向量对向量、矩阵对矩阵导数的定义是按照雅克比矩阵方式的，而你这里的定义和“Matrix Calculus: Derivation and Simple Application”一样是海森矩阵方式的，能否提供一下按照海森矩阵方式定义导数的参考文献。

👍 2



排骨郎

2017-03-16

例3中，与B的转置做 kronecker product 的单位矩阵应该是  $I_m$  不是  $I_n$

👍 2



长躯鬼侠 (作者) 回复 排骨郎  
多谢指正

2017-03-16

👍 赞



James Liu

2017-01-21

先赞为敬

👍 2



树叶的一生

2020-02-20

请问，例4倒数第二行怎么推出来的，没有向量化怎么破解那个元素相乘

👍 1



长躯鬼侠 (作者) 回复 树叶的一生

2020-02-20

注意  $\sigma'(Xw) \odot (Xdw)$  已经是向量了，所以再做向量化也还是它。

👍 2



skrskr

2019-10-09

两篇看下来，不可多得的好文





## 知乎

 1


知乎用户

2017-12-11

能区分一下行列求导就更完美了，同时使用线性变换解释一下导数与微分的关系，可能更加恰当，和利于直觉。

 1


暮日落流年

2017-12-10

收益匪浅，赞一个！

 1


孙培钦

2017-09-29

我想问一下，假设我有个等式  $S = WX$ ， $S$  是  $m \times 1$  向量， $X$  是  $n \times 1$  向量， $W$  是  $m \times n$  矩阵，使用上述的求导术去求  $S$  向量对  $X$  向量的导数，我得到的是一个  $n \times n$  的单位阵与  $W$  转置的 kronecker 积啊，这个积的尺寸应该是  $nn \times mn$ ，明显不对啊。

 1


长躯鬼侠 (作者) 回复 孙培钦

2017-09-29

$ds = W^T dx$ ， $x$  的右面是  $1 \times 1$  的单位阵，不是  $n \times n$  的。

 1


陌烛

2017-08-26

你好，请问下，为何例二中， $f$  对  $X$  的二阶导没有进行转置？在原文（例二中）：“对照导数与微分的关系得到……”后面的那个式子

 1


长躯鬼侠 (作者) 回复 陌烛

2017-08-28

是对称矩阵，转置等于它自己。

 2


树叶的一生 回复 长躯鬼侠 (作者)

2020-02-19

是算出来转置等于他自己嘛

 赞

展开其他 2 条回复



DreamYun

2017-08-



知乎

链式求导法则。其它形式的求导方法，可能不适用复合函数求导链式法则。

👍 1



Shinji Fujiwara

2017-03-10

赞

👍 1



净行而溢

07-24

例4中求一阶导数的时候只用上篇的求导法则如何求啊，式中 $\log(1+\exp(XW))$ 是向量啊，没法做分母啊🤔，请大佬指点😁

👍 赞



长躯鬼侠 (作者) 回复 净行而溢

昨天 00:38

把 $1/x$ 看成逐元素函数， $1/(1+\exp(Xw))$ 就是 $Xw$ 逐元素求指数、再求倒数。

👍 赞



净行而溢 回复 长躯鬼侠 (作者)

昨天 10:25

哇，谢谢大佬指点👍

👍 赞



我命由我不由天

04-25

非常好的文章，感觉自己现在无敌了！



👍 赞

